

程序文档

A 组

UTF-8 字符串解析

按照 UTF-8 编码解析字符串，并封装为 Utf8String 类型的对象

Utf8String

成员类型

成员类型	定义
data_type	std::u32string
value_type	data_type::value_type
raw_type	std::string
size_type	data_type::size_type
reference	value_type&
const_reference	const value_type&
pointer	value_type*
const_pointer	const value_type*

成员函数

函数名	功能
(构造函数)	构造 Utf8String
(析构函数)	销毁字符串
front	访问首字符
back	访问最后的字符
clear	清除内容
push_back	后附字符到结尾
substr	返回子串
size	返回字符数
length	返回字符数
empty	检查字符串是否为空
raw	返回 std::string 类型的版本
c_str	返回不可修改的 C 字符数组版本
find	于字符串中查找字符(串)
operator=	为字符串赋值
operator[]	访问指定字符
operator+=	后附字符(串)到结尾
operator+	连接两个字符串或者一个字符串和一个字符
operator==	以字典序比较两个字符串是否相等
operator!=	以字典序比较两个字符串是否不相等

operator<	以字典序比较两个字符串
operator<<	执行字符串的流输入
operator>>	执行字符串的流输出

中文分词

依赖 Utf8String 类型,对中文基于信息量实现分词操作,并封装成一个可以直接获取分词结果的接口

InfoQuantity

封装词语信息量的查询操作

接口

接口定义	功能
double get_infoquantity(const Utf8String &word);	接受一个词,并返回该词的信息量
bool count(const Utf8String &word);	接受一个词,并返回该词在词频文件是否存在

Segmentation

接口

接口定义	功能
std::vector<Utf8String> segment(const Utf8String &sentence);	接口接受一个 UTF-8 编码的 Utf8String 类型的字符串,并返回分词之后的词语集合.该接

	口保证返回词语集合的顺序与其在原句中的次序相同.
--	--------------------------

倒排索引

封装倒排索引,实现如下功能:

1. 倒排索引的建立
2. 根据关键词进行检索
3. 对象到文件的序列化
4. 文件到对象的反序列化

FileInfo

描述单个关键词与单个文件之间联系的结构体

包含以下信息:

1. 关键词所在文章的文件路径
2. 关键词在该文章中出现的次数和频率
3. 关键词是否出现在文章的标题中

KeywordInfo

描述单个关键词在单个文件中的信息的信息的结构体

包含以下信息:

1. 关键词在该文章中出现的次数和频率
2. 关键词是否出现在文章的标题中

InvertedIndex

成员类型

成员类型	定义
key_type	Utf8String
value_type	std::vector<FileInfo>
data_type	std::map<key_type, value_type>

成员函数

函数名	功能
(构造函数)	建立倒排索引
ready	返回该倒排索引是否已建立成功
serialize	由对象序列化到文件
unserialize	由文件反序列化到对象
get_filepaths	检索给定关键词,返回检索结果,只包含结果的文件路径
add_files	根据给定文件夹路径,添加新的索引
add_file	根据给定文件路径,添加新的索引

检索服务器

基于 Socket 的 UNIX 域实现进程间通信, 并通过多线程优化多进程访问时的效率

Request

规定与其它进程通信的细节

包含以下信息:

- 1. 检索的类型
- 2. 检索的关键词列表

SearchServer

封装服务器的行为,只提供监听和启动操作,隐藏实现细节

成员函数

函数名	功能
(构造函数)	构造 SearchServer, 初始化套接字
listen	开始监听外部请求
run	进入主循环,处理外部检索请求

B 组

1. 前端部分

前端部分的文件及其调用关系、输入输出、功能如下表所示

文件名称	调用关系	输入	输出	功能
index.php	->SearchEnter. php	搜索类别、公式、 关键词	GET 方式传参到 SearchEnter .php, 页面跳转	整个搜索引擎的 入口

SearchEnter.php	->Index2ResultList.php/Index2ConceptMap.php	搜索类别、公式、 关键词	GET 方式传参到 Index2ResultList.php 或 Index2ConceptMap.php, 页面跳转	1. 根据搜索类别来决定调用结果列表模块还是知识图谱 2. 更改加号不引起 GET 错误
Index2ResultList.php	GetResultList.php->LaTeXTransfer.php->	搜索类别、公式、 关键词	文件路径、文件名、摘要文本	搜索结果列表的生成和显示
Index2ConceptMap.php	GetResultList.php->LaTeXTransfer.php->	公式、关键词	概念图谱、文件路径、文件名、摘要文本	概念图谱的生成和显示
GetResultList.php	EncapAndDecap.php->UnixDomainSocket.php->	搜索类别、公式、 关键词	包含了文件路径、文件名、摘要文本列表的类	封装请求参数和响应数据, 中间层
EncapAndDecap	MessageClasses	搜索类别、公式、 关键词/响应数据	搜索类别、公式、 关键词/响应数据切分数组	传输数据和应用数据双向封装
UnixDomainSocket	/	搜索类别、公式、	响应数据	Unix 域本地套

ocket.php		关键词		接字系列操作封装函数
MessageClasses	/	/	/	定义了包含了文件路径、文件名、摘要文本列表的类
LaTeXTransfer.php	/	LaTeX 公式原始字符串、关键字	加上高亮标记的关键字、映射成文件的 LaTeX 公式	关键词高亮和 LaTeX 显示映射
Page.php	/	文件路径	文件内容	文件具体内容显示页面

2. 后端部分

2.1 摘要求解

2.1.1 模块介绍

AbstractBuilder(); 构造函数

~AbstractBuilder(); 析构函数

void InitKeyword(LISTSTR); 初始化关键词

void ParseFile(LISTSTR); 解析文章

string FileReader(LISTSTR); 读取文章

LISTSTR SentenceFilter(string); 按关键词逐个进行语句切分

PRIQUEUESTR DivideSentence(string, char); 语句切分

float ScoreSentence(string); 语句打分

void CheckSentence(LISTSTR); 避免语句重复

void GetAbstract(LISTSTR); 拼接摘要

string Abstract(); 获取摘要

备注: typedef list<string> LISTSTR;

typedef priority_queue<STC> PRIQUEUESTR;

typedef list<string>::iterator LISTSTRITER;

2.1.2 功能介绍

1.将一篇文章按照分隔符分成若干个句子

2.统计句子里面关键字出现的次数, 和关键字总长度占句子总长度的比值

3.按下列公式计算句子的优先级

$$\frac{\sum_{n=1}^i \text{length}_i}{\text{length}_{\text{sentence}}} * \text{weight}_1 + \sum_{n=1}^i \text{times}_i * \text{weight}_2 + \text{length}_{\text{sentence}} * \text{weight}_3$$

注: length - 长度, weight - 超参数, times - 出现次数

4.句子按优先级进入优先队列 (排序规则重载为降序), 选择 topN 拼接成为摘要

2.2 变量替换

2.2.1 模块介绍

VarIndep(); 构造函数

~VarIndep(); 析构函数

char GetSymbol(string); 返回变量替代符

2.2.2 功能介绍

根据变量出现的次序来依次将它们替换为不同符号（有规律）

2.3 运算符优先级

2.3.1 模块介绍

void InitConfigure(); 序列化优先级配置文件

char GetPriority(string, string); 运算符获得优先级

void CheckTable(); 检查配置文件工具

2.3.2 功能介绍

输入 LaTeX 格式的运算符，获取它的优先级。

优先级一览表如下：

优先级	符号列表
0	$\backslash\text{because}$ $\backslash\text{therefore}$ $\backslash\text{perp}$ $\backslash\text{parallel}$ $\backslash\text{neq}$ $=$ $\backslash\text{cong}$ $>$ $<$ $\backslash\text{leq}$ $\backslash\text{geq}$ $\backslash\text{le}$ $\backslash\text{geq}$

2	+ -
3	* /
4	\frac \sqrt ^ \sin \cos \tan
5	() [] {} \lvert \rvert
6	\triangle \square \angle \%